



Ford Argentina
Ford Innovation Challenge III · AI Edition · 2026

Ford Innovation Challenge III: AI Edition

Informe de la Solución

Desafío: Data-Driven Powertrain Intelligence

Powertrain Health Copilot: predicción temprana de la degradación del filtro de partículas

Equipo: San Miguel

Integrantes			
Nombre y apellido	Universidad	Carrera	Correo electrónico
Ameri, Patricio	UADE	Ing. Informática	pameri@uade.edu.ar
Ponce de Leon, Mateo	UADE	Ing. Informática	maponcedeleon@uade.edu.ar
Gamallo, Lautaro	UADE	Ing. Informática	lgamallo@uade.edu.ar

Índice

1. Descripción del Desafío	2
2. Descripción de la Solución	3
2.1. Resumen Ejecutivo de la Solución	3
2.2. Especificaciones Técnicas	3
2.2.1. Arquitectura general	4
2.2.2. Datos: calidad y preparación	4
2.2.3. La señal que anticipa el evento	6
2.2.4. Variables y etiquetas	6
2.2.5. Modelos	7
2.2.6. Protocolo de validación	8
2.2.7. Resultados	8
2.2.8. Explicabilidad	10
2.2.9. Validación temporal y límites del desempeño	10
2.2.10. Copiloto del conductor	11
2.2.11. Alerta a bordo	12
2.2.12. Información Complementaria	13
2.3. Seguridad y Privacidad	14
3. Factibilidad Económica	16
4. Valor Diferencial e Innovación	18
5. Trabajo Futuro	19
6. Conclusiones	20

● Descripción del Desafío

Título del desafío: Metodología de Inteligencia Artificial para la predicción temprana de eventos de degradación en la eficiencia de combustión e ingreso de oxígeno al motor, a partir de datos de vehículos conectados.

Área: Data-Driven Powertrain Intelligence.

Los vehículos diésel de Ford reportan de forma continua su estado a la nube mediante telemetría: un resumen de cada viaje y los mensajes de la ECU sobre el sistema de postratamiento. Hoy ese caudal de datos se usa de forma reactiva. La degradación se detecta cuando ya se manifestó, en un service o cuando el cliente percibe la pérdida de potencia o la luz de advertencia.

El desafío plantea que parte de esa degradación se origina en el uso: trayectos predominantemente cortos, uso urbano intensivo y operación que no permite completar los ciclos naturales de recuperación del sistema. En los datos entregados, el componente que concentra ese mecanismo es el **filtro de partículas diésel o DPF**. El filtro retiene el hollín del escape y se limpia quemándolo en un proceso llamado regeneración, que necesita temperatura sostenida durante varios minutos. Cuando los viajes son cortos, la regeneración no llega a completarse, el hollín se acumula y el motor pierde eficiencia hasta que hace falta una intervención en el concesionario.

Se pide un modelo que, a partir de los patrones históricos de uso y de las variables del motor, anticipe con la mayor cantidad de tiempo y kilometraje posible el momento en que un vehículo se acerca a ese evento, para habilitar mantenimiento predictivo y preventivo antes de que el cliente note el problema.

Tabla 1. Cómo se organiza la respuesta a los criterios del desafío.

Criterio de evaluación	Dónde se responde en este informe
Viabilidad técnica	2.2: arquitectura, validación por vehículo y temporal.
Costo	3: costos de implementación y mantenimiento, modelo de ahorro con sensibilidad
Carácter innovador	4: predicción, prescripción al conductor y alerta a bordo desde un mismo modelo
Tratamiento de datos	2.2.2: limpieza trazable, reconstrucción del calendario y de las regeneraciones
Claridad de visualización	Figuras del informe y dashboard de cuatro vistas descripto en 2.2.12
Explicabilidad	2.2.8: SHAP por grupo y por vehículo, atención temporal de la red, Health Index

• Descripción de la Solución

• Resumen Ejecutivo de la Solución

Powertrain Health Copilot es un sistema que, todos los días y para cada vehículo, estima la probabilidad de que ocurra un evento de degradación del DPF en los próximos 30, 60 y 90 días a partir de la telemetría que Ford ya recibe. Además explica qué hábitos empujan ese riesgo y lo convierte en tres salidas concretas: un ranking de la flota para la red de concesionarios, una recomendación de manejo simple para el conductor y una versión compacta que corre dentro del vehículo.

El resultado principal se midió en 198 vehículos que el modelo nunca vio durante el entrenamiento. Con la misma tasa de falsas alarmas que la advertencia actual de la ECU, el sistema detecta el **88 % de los eventos antes de que ocurran**, contra el 55 % de la ECU, con una anticipación mediana de 125 días o unos 4.350 km.

88 %	125 días	4.354 km	0,61
eventos detectados antes de ocurrir (ECU: 55 %)	anticipación mediana de la primera alerta	recorridos entre la alerta y el evento	falsas alarmas por vehículo sano y año




Figura 1. Detección anticipada frente a la advertencia actual de la ECU, a igual tasa de falsas alarmas. Holdout de 198 vehículos y 56 eventos; las barras de error son intervalos de confianza del 95 %.

La solución resuelve el desafío porque ataca la causa y no solo el síntoma. Además de avisar, indica qué cambio de hábito baja el riesgo: por ejemplo, un trayecto de 20 minutos o más por semana, que en los datos completa la limpieza del filtro en el 93 % de los casos. Es viable porque usa solo datos que ya existen, no requiere hardware nuevo, corre en CPU con herramientas de código abierto y su versión a bordo ocupa 290 bytes de memoria por vehículo.

La evaluación se hizo con criterios estrictos y se reportan también los límites. Cuando se simula la puesta en producción en una fecha pasada, la ventaja sobre la ECU se mantiene pero es menor, y la causa principal es la cantidad de vehículos con evento disponibles para entrenar. Reentrenar el modelo cada mes y sumar vehículos son las dos palancas medidas para cerrar esa brecha.

• Especificaciones Técnicas

Esta sección describe cómo funciona la solución, por qué cada decisión se tomó de esa forma y cómo se verificó. Todos los resultados provienen de la ejecución completa del pipeline

incluido en el repositorio.

• **Arquitectura general**

El sistema es un pipeline por etapas. Cada etapa lee y escribe archivos en disco, de modo que puede volver a ejecutarse por separado y sus resultados se pueden inspeccionar. Los datos se procesan con DuckDB con un límite de memoria configurable, lo que permite trabajar con los 12 millones de registros en una computadora de 16 GB.



Figura 2. Arquitectura de Powertrain Health Copilot, desde la telemetría cruda hasta las tres salidas.

Tabla 2. Módulos del pipeline.

Etap	Módulo	Qué hace
Datos	src/data.py	Carga 2,5 millones de viajes y 9,9 millones de eventos de la ECU, limpia con reglas trazables, reconstruye el calendario y las regeneraciones y agrega por vehículo y día.
Variables	src/features.py	Construye 170 variables que miran solo hacia atrás y las etiquetas a 30, 60 y 90 días con censura. Incluye un test automático contra fuga de información.
Modelos	src/models.py	Entrena el ensamble con validación cruzada agrupada por vehículo y el modelo monótono para simular cambios de hábito.
Evaluación	src/evaluate.py, src/temporal.py	Métricas con intervalos de confianza por vehículo, políticas de alerta, comparación con la ECU, SHAP y validación temporal.
Reentren	src/retrain.py	Re entrena cada mes los modelos LightGBM con las etiquetas conocidas a la fecha, guarda una versión por mes, controla al candidato contra el modelo vigente y permite volver a una version anterior.
Salidas	app.py, app_lgbm.py, src/copilot.py, src/edge.py	Dashboard de flota y vehículo, entrenamiento del LightGBM aislado, recomendaciones al conductor y exportación del modelo a C.

• **Datos: calidad y preparación**

Se trabajó con tres familias de tablas, separadas en vehículos con y sin evento: información estática de 992 vehículos, resúmenes de viaje y eventos de telemetría de la ECU. El dataset está anonimizado y su esquema real difiere del anexo de la consigna, por lo que primero se

estableció qué mide cada columna. Por ejemplo, las columnas rotuladas como filtro de aire contienen en realidad el estado del DPF, ya que sus mensajes siguen el ciclo de un filtro de partículas: normal, lleno, sobre el límite y limpieza automática. Varios hallazgos de datos fueron decisivos para que el modelo aprenda la física del problema y no artefactos:

1. **Etiquetas corregidas.** En la primera versión del archivo de fallados, la fecha de identificación coincide con la fecha de venta en el 76 % de los casos, así que no es la fecha de falla. Se usó exclusivamente la versión 2.
2. **Calendario reconstruido.** La fecha de producción viene como días desde un origen desconocido y distinto en cada archivo. Se estimó ese origen suponiendo que el primer viaje ocurre en planta; la hipótesis se validó porque el residuo tiene una dispersión de apenas 0,65 días entre los percentiles 5 y 95. Así cada evento queda ubicado en el calendario de la telemetría.
3. **Corte de telemetría recuperado.** Desde el 26 de mayo de 2026 no llega ningún evento de regeneración en toda la flota, aunque siguen llegando 3,2 millones de mensajes. Usada tal cual, esa señal hacía subir el riesgo medio de los vehículos sanos de 4 % a 41 %. Las regeneraciones se reconstruyeron desde la carga de hollín, que nunca dejó de llegar: una regeneración es una caída de al menos 20 puntos entre lecturas consecutivas.
4. **Sesgo de cohorte controlado.** Los vehículos con evento se produjeron desde 2023 y los sanos desde 2025. Por eso la edad, el odómetro y la fecha nunca son variables del modelo, y los acumulados se reemplazaron por tasas. Si no, el modelo aprendería que un auto viejo falla en lugar de aprender cómo se satura el filtro.
5. **Conflictos y duplicados.** Se excluyeron 27 vehículos sanos que figuran en alguna lista de fallados y 40.760 viajes duplicados. Los 19 vehículos con más de un evento se modelan reiniciando el reloj tras cada service.

Tabla 3. Validación de la reconstrucción de regeneraciones contra la bandera original, antes del corte.

Regla de reconstrucción	Recall	Precisión
Hollín previo de 30 o más y actual de 10 o menos	0,64	0,88
Caída de 20 puntos o más (elegida)	0,91	0,81
Caída de 15 puntos o más	0,94	0,80

La regla elegida tiene además una correlación de 0,88 con la bandera a nivel vehículo y mes, y una tasa estable de entre 2,5 y 3 regeneraciones cada 1.000 km antes y después del corte. Con ella se reconstruyeron 88.437 episodios y se recuperó el período completo, lo que sumó un 37 % más de casos positivos a 30 días. La regla de 15 puntos recupera algo más (0,94 contra 0,91) con precisión similar, pero se eligió la de 20 por ser más conservadora frente al ruido de lectura del sensor de hollín.

Tabla 4. Limpieza de viajes. Cada regla queda registrada en data/quality.json; el dashboard muestra el resumen.

Regla de limpieza de viajes	Viajes descartados
Duración mayor a 24 horas	224
Odómetro decreciente	274
Viaje mayor a 1.500 km	5

Regla de limpieza de viajes	Viajes descartados
Velocidad media mayor a 200 km/h	288
Duplicados de vehículo y hora de inicio	40.760
Viajes válidos resultantes	2.476.875

Los valores fuera de rango físico, como temperaturas de -73°C o -128°C que el sensor usa como valor centinela, se convierten en faltantes en lugar de descartar la fila. Todos los archivos se leen como texto y se convierten con conversión tolerante, de modo que un valor malformado no interrumpe la carga.

• **La señal que anticipa el evento**

Antes de modelar se verificó que existe una señal previa al evento. La Figura 3 alinea a todos los vehículos fallados en la fecha de su evento. En los 90 días previos, la proporción de mensajes que reportan el filtro sobre el límite se multiplica por cuatro, de 0,6 % a 2,4 %, y los viajes muy cortos aumentan. La frecuencia de regeneraciones, en cambio, casi no cambia antes del evento, entre 3,5 y 3,6 cada 1.000 km, y sube después del service, a entre 4,0 y 4,6: lo que anticipa el evento es la saturación del filtro, no que dejen de ocurrir limpiezas. Después del service todo vuelve a la normalidad. Esa es la ventana que el modelo aprovecha.




Figura 3. Comportamiento de los vehículos fallados alineados en la fecha del evento, en bloques de 30 días. La franja sombreada marca los 90 días previos.

• **Variables y etiquetas**

Cada vehículo se lleva a un calendario de días consecutivos y cada día con uso es un punto de predicción. Sobre ese calendario se calculan 170 variables que solo miran el pasado:

- Ventanas de 7, 30 y 90 días** de intensidad de uso, proporción de viajes cortos, urbanos, sin llegar a temperatura y con arranque en frío, carga de hollín, mensajes del DPF y regeneraciones. Las proporciones se ponderan por cantidad de viajes o de mensajes.
- Tendencias**, como la diferencia entre la ventana de 7 y la de 90 días, que capturan la aceleración de la degradación.
- Estado del ciclo de regeneración:** kilómetros y días desde la última regeneración completa.
- Desvío respecto de la propia historia:** cuánto se aleja hoy el vehículo de su comportamiento habitual. Así el modelo compara cada auto consigo mismo y no solo con la flota.

10. Motor, serie y país como variables categóricas.

La etiqueta de cada día indica si ocurre un evento dentro de los próximos 30, 60 o 90 días. Un día sin evento solo cuenta como negativo si se observaron completos los días siguientes; si los datos terminan antes, la etiqueta queda como desconocida. Al ejecutar el módulo de variables se corre un test que recalcula las variables de un vehículo con su historia cortada a la mitad y verifica que los días anteriores al corte den exactamente igual. Si alguna variable dependiera del futuro, el test falla.

Tabla 5. Etiquetas por horizonte. La baja tasa de positivos exige métricas adecuadas a clases desbalanceadas.

Horizonte	Días válidos	Días positivos	Tasa
30 días	256.426	5.938	2,3 %
60 días	235.403	11.938	5,1 %
90 días	215.449	18.158	8,4 %

• Modelos

Se combinaron modelos con enfoques distintos para que cada uno aporte una mirada propia del problema. La combinación final se entrena solo con predicciones fuera de fold, es decir, hechas sobre vehículos que cada modelo no vio.

Tabla 6. Modelos del ensamble.

Modelo	Rol en la solución
LightGBM	Componente principal. Un clasificador por horizonte con hiper parámetros elegidos en una grilla de 8 configuraciones evaluadas solo con los folds de entrenamiento.
Red neuronal híbrida	GRU con atención sobre 180 días de telemetría diaria más las 170 variables del día. Su salida es un riesgo semanal a 26 semanas, del que se obtienen probabilidades coherentes entre horizontes y los días restantes estimados.
Random Survival Forest	Modelo de supervivencia que estima la probabilidad acumulada del evento en el tiempo y la vida útil remanente.
Autoencoder	Entrenado solo con vehículos sanos. Su error de reconstrucción define un Health Index de 0 a 100 fácil de comunicar.
Stacking	Regresión logística que combina los anteriores y entrega probabilidades calibradas: Brier de 0,064 a 90 días.
LightGBM monótono	Variante con restricciones físicas: más viajes cortos o regeneraciones interrumpidas nunca bajan el riesgo, y viajes más largos nunca lo suben. Se usa para simular cambios de hábito.

La red neuronal se entrenó en GPU con parada temprana y cinco semillas, pero el código no depende de la GPU: dispositivo, precisión y parámetros salen de un archivo de configuración por máquina y todo corre también en CPU. La red alcanzó el nivel del LightGBM, con un AUC de 0,82 a 30 días, aunque aporta poco al ensamble porque aprende casi la misma información.

La red cumple además un rol a futuro: está desarrollada, integrada al pipeline y lista para crecer con los datos. En la curva de aprendizaje mejora al mismo ritmo que el LightGBM al sumar vehículos: su AUC a 90 días sube de 0,73 a 0,78, contra 0,74 a 0,80, y ninguna de las dos

curvas se aplanan. Como lee la telemetría diaria sin depender de variables construidas a mano y puede pre-entrenarse con vehículos sin etiqueta, es el componente que mejor puede aprovechar los volúmenes de una flota en producción. Con los datos actuales el pre-entrenamiento auto-supervisado mejoró los resultados fuera de fold pero no la validación temporal, por lo que no se adoptó; es una línea a retomar cuando haya más datos.

- **Protocolo de validación**

El protocolo se diseñó para que los números reflejen lo que pasaría con vehículos y fechas nuevas:

11. **Partición por vehículo.** Un 20 % de los vehículos, 198 en total, queda reservado como holdout y nunca se usa para entrenar ni para decidir nada. El resto se divide en 5 folds agrupados por vehículo, porque los días consecutivos de un mismo auto son casi idénticos y partir por filas filtraría su identidad.
12. **Decisiones fuera del holdout.** Hiper Parámetros, arquitectura, pesos del ensamble y umbral de alerta se eligen con predicciones fuera de fold de los vehículos de entrenamiento.
13. **Intervalos de confianza por vehículo.** Se remuestrea vehículos completos, ya que las filas de un mismo auto están correlacionadas.
14. **Validación temporal.** Se simula la puesta en producción el 1 de enero de 2026: se entrena solo con lo que se sabía en esa fecha y se evalúa después.
15. **Comparación con la ECU.** La línea base es la advertencia actual: alerta si hubo un mensaje de filtro sobre el límite en los últimos 7 días.

- **Resultados**

Tabla 7. Discriminación del ensamble en el holdout de 198 vehículos.

Horizonte	AUC holdout e IC 95 %	AUC fuera de fold	AP holdout	Tasa base	AUC solo fallados
30 días	0,83 [0,78; 0,88]	0,85	0,21	0,02	0,74
60 días	0,80 [0,76; 0,86]	0,82	0,29	0,05	0,70
90 días	0,79 [0,74; 0,84]	0,81	0,32	0,08	0,68

El AUC fuera de fold y el del holdout coinciden, lo que indica que el modelo generaliza a vehículos nuevos. La precisión promedio o AP multiplica entre 4 y 9 veces la tasa base. La última columna evalúa solo vehículos que fallan: mide si el modelo sabe cuándo se acerca el evento sin poder apoyarse en diferencias entre grupos de vehículos, y confirma que la señal temporal es real.

Para uso operativo, la probabilidad diaria se suaviza con una media de 7 días y se convierte en alerta. Se compararon dos políticas. El **umbral fijo** alerta cuando el riesgo supera un valor. El **umbral relativo** alerta cuando el vehículo está en el 20 % de mayor riesgo de la flota en los últimos 30 días; no usa etiquetas, se calcula en producción y fija el volumen de alertas por diseño, lo que permite ajustarlo a la capacidad de los concesionarios. El punto de operación se eligió fuera de fold como el de mayor detección sin superar la tasa de falsas alarmas de la

ECU.




Figura 4. Detección frente a falsas alarmas en el holdout. Cada punto de las curvas es un umbral distinto; el punto naranja es la advertencia actual de la ECU.

Tabla 8. Alertas en el holdout, 56 eventos.

Política	Detección e IC 95 %	Anticipación mediana	Falsas alarmas por vehículo y año
Advertencia ECU actual	55 % [43; 68]	100 días, 4.313 km	0,60
Umbral fijo	84 % [73; 93]	105 días, 3.702 km	0,65
Umbral relativo, top 20 %	88 % [79; 96]	125 días, 4.354 km	0,61

La ventaja es en cuántos eventos se detectan: 32 puntos más que la ECU con la misma tasa de falsas alarmas. En anticipación, medida en días o en kilómetros sobre los eventos detectados, la diferencia está dentro del ruido. La misma comparación sobre los 237 eventos de entrenamiento, fuera de fold, da 92 % contra 53 %. La Figura 5 muestra cómo se ve esto en un vehículo concreto del holdout.

Variabilidad entre corridas. La red neuronal se entrena en GPU con precisión mixta, un proceso que no es completamente determinista, y como la red forma parte del ensamble, dos ejecuciones completas del pipeline pueden dar resultados levemente distintos. Entre la corrida anterior y la última, los datos, el LightGBM, el modelo de supervivencia, la validación temporal y la alerta a bordo dieron exactamente igual, mientras que la detección con umbral relativo pasó de 89 % a 88 %. Es una diferencia de un evento sobre 56, dentro del intervalo de confianza, y no cambia ninguna conclusión. Las cifras de este informe corresponden a la última corrida completa, del 1 de octubre de 2026.




Figura 5. Un vehículo del holdout: el riesgo supera el umbral de la flota 129 días antes del evento, mientras que la ECU no emite advertencias en ese período.

- **Explicabilidad**

Cada predicción se puede explicar a tres niveles. A nivel global, los valores SHAP agrupados por hipótesis física muestran que el riesgo lo explican sobre todo las regeneraciones y el patrón de uso, seguidos por la carga de hollín. A nivel de vehículo, el dashboard muestra los grupos de hábitos que más empujan el riesgo en el día elegido, sin contar el país ni el modelo del vehículo, y los traduce en una receta concreta. A nivel temporal, la atención de la red indica qué días de los últimos seis meses empujaron el riesgo.




Figura 6. Importancia de cada grupo de variables en el modelo a 90 días, medida con SHAP sobre 5.000 días del holdout.

El país es individualmente la variable más influyente y puede reflejar en parte cómo se armaron las listas de vehículos fallados y sanos. Por eso se hizo una prueba sin las variables de vehículo y mercado: el AUC general baja entre 0,02 y 0,05, pero el AUC dentro de los fallados casi no cambia. La información de cuándo llega el evento viene de la telemetría.

- **Validación temporal y límites del desempeño**

El holdout por vehículo comparte período y estacionalidad con el entrenamiento, así que puede ser optimista. En la simulación de puesta en producción del 1 de enero de 2026, los umbrales se eligieron con los 90 días previos a esa fecha y considerando sano a todo vehículo sin evento conocido en ese momento.

Tabla 9. Validación temporal. FA: episodios de falsa alarma por vehículo y año.

Escenario	AUC 30 d	AUC 90 d	ECU: detección y FA	Fijo: detección y FA	Relativo: detección y FA
Vehículos nuevos, 36 eventos	0,72	0,64	53 % y 0,90	50 % y 0,51	64 % y 0,66
Misma flota, 194 eventos	0,72	0,66	43 % y 0,88	49 % y 0,40	38 % y 0,28

Hacia el futuro el desempeño cae y en ambos escenarios alguna de las dos políticas iguala o supera la detección de la ECU con menos falsas alarmas (con la misma flota, el umbral fijo 49 % contra 43 %), aunque con vehículos nuevos la ventaja está dentro del ruido estadístico. Un diagnóstico específico explicó la caída: cerca del 40 % se debe a que en la fecha simulada solo había 66 vehículos con evento para entrenar, contra 217 hoy, y el 60 % restante a un cambio en la relación entre uso y evento a medida que la flota envejece. Los eventos por cada 100 vehículos activos pasaron de 1,3 por trimestre a comienzos de 2025 a 8,6 a comienzos de 2026.




Figura 7. Izquierda: AUC a 90 días en el holdout y en la simulación de producción, con el efecto del reentrenamiento mensual. Derecha: curva de aprendizaje según la cantidad de vehículos de entrenamiento.


Dos resultados orientan los próximos pasos. Reentrenar cada mes mejora el AUC de la flota ya monitoreada entre 0,035 y 0,038, una diferencia estadísticamente significativa. Y cada duplicación de la cantidad de vehículos suma unos 0,03 de AUC sin que la curva se aplane, mientras que sumar días por vehículo no aporta. Se probaron también combinar el modelo con la advertencia de la ECU y dar más peso a los datos recientes; ninguna de las dos mejoró fuera del ruido.

Reentrenamiento mensual implementado. El reentrenamiento ya es parte del pipeline (src/retrain.py) y se programa para correr el primer día de cada mes, después de actualizar los datos y las variables. Si el test contra fuga de información falla, el reentrenamiento no corre. Entrena los modelos LightGBM de los tres horizontes con todos los vehículos, usando solo las etiquetas que se conocen a esa fecha, y guarda cada versión junto con sus métricas. Publicar o volver a una versión anterior consiste en cambiar cuál es la versión vigente, sin tocar el resto del sistema. Cada mes se registran dos controles. El primero es el desempeño real del modelo vigente sobre los eventos que se conocieron desde su publicación, que nunca vio. El segundo es el AUC del modelo candidato con validación cruzada por vehículo; el candidato se rechaza si queda claramente por debajo del vigente. En una simulación con reentrenamientos el 1 de enero y el

1 de febrero de 2026, el modelo vigente obtuvo en producción un AUC de 0,76, 0,70 y 0,73 a 30, 60 y 90 días, en línea con la validación temporal. Cada reentrenamiento tarda menos de 3 minutos en CPU.

• **Copiloto del conductor**

Avisar no alcanza: el cliente necesita saber qué hacer. El copiloto traduce el riesgo en una acción concreta y medida con los datos. Primero se midió qué viaje sirve para regenerar: de los 1.670 viajes que empiezan con una regeneración en curso, la limpieza termina antes de apagar el motor en el 30 % de los de menos de 5 minutos y en el 93 % de los de 20 minutos o más, casi sin importar la velocidad..



3

Figura 8. Porcentaje de regeneraciones que terminan dentro del viaje, según la duración del viaje.

- 16. **Receta mínima.** Recorre combinaciones de cambios de hábito, como sumar trayectos de ruta por semana, reducir viajes cortos o no cortar la limpieza, y elige la de menor esfuerzo que saca al vehículo de la zona de alerta según el modelo monótono. Si ninguna alcanza, deriva al concesionario.
- 17. **Ventana de regeneración.** Con las últimas 12 semanas de viajes del vehículo identifica en qué día y franja horaria suele hacer un trayecto apto. El consejo se adapta: no acortar ese viaje, estirar un viaje de 10 a 20 minutos o planificar uno nuevo.

Ejemplo de mensaje al conductor

"Tu filtro de partículas está acumulando hollín más rápido que lo habitual. Los jueves a la tarde solés hacer un trayecto de más de 20 minutos: mantenelo esta semana y sumá uno más de ruta. Con eso tu riesgo baja a la mitad."

En el primer día de alerta de los 119 vehículos del holdout que entran en alerta, la receta alcanza en el 85 % de los casos en que el manejo tiene margen de mejora, con una reducción

mediana del riesgo simulado del 46 %. En el 22 % el riesgo no viene del manejo reciente y el caso va directo al concesionario. Son simulaciones con el modelo y no efectos causales medidos; confirmarlos requiere el piloto descrito en Trabajo Futuro.

- **Alerta a bordo**

Para vehículos sin conectividad permanente o para una alerta inmediata en el tablero, se diseñó una versión que corre en la ECU o en el módulo telemático. A bordo no hay 90 días de historia ni riesgo de la flota, así que las variables se reemplazan por medias móviles exponenciales con vida media de 7 y 30 días sobre 17 series diarias, más contadores desde la última regeneración, y el umbral es fijo.




Figura 9. Detección del modelo compacto a bordo frente a la ECU, exigiendo no superar ni sus episodios de falsa alarma ni sus días sanos en alerta.

Tabla 10. Alerta a bordo: 100 árboles de 7 hojas.

Escenario	ECU: detección, FA, días sanos en alerta	Modelo a bordo	Diferencia de detección e IC 95 %
Holdout	55 %, 0,60, 5,3 %	77 %, 0,53, 3,5 %	+21 puntos [+5; +36]
Futuro, vehículos nuevos	53 %, 0,90, 5,9 %	58 %, 0,74, 4,3 %	+6 puntos [-8; +22]
Futuro, misma flota	43 %, 0,88, 7,5 %	65 %, 0,73, 3,0 %	+23 puntos [+13; +31]

El modelo se exporta a C99 sin memoria dinámica ni recursión. El estado ocupa 290 bytes por vehículo y las tablas del modelo unos 17 KB en doble precisión, la mitad en precisión simple. La función de actualización se llama una vez por día. La paridad con Python se verificó sobre 19.534 días de 40 vehículos: la diferencia máxima de puntaje es de $9 \cdot 10^{-16}$ y las alertas son idénticas.

- **Información Complementaria**

Se adjuntan en el archivo .zip los siguientes entregables:

18. **Repositorio completo** con el pipeline reproducible, un comando por etapa, y el archivo de requisitos con versiones fijadas.
19. **Dashboard en Streamlit** con cuatro vistas, sobre los 198 vehículos que el modelo nunca vio. Flota: vehículos monitoreados, vehículos en alerta y ranking por riesgo.

Vehículo: riesgo en el tiempo con el umbral de la flota, las advertencias de la ECU y los eventos; los hábitos que más empujan el riesgo; la receta mínima, la ventana de regeneración y el simulador de hábitos. Resultados: detección frente a falsas alarmas comparada con la ECU, peso de cada grupo de variables y ahorro anual con supuestos editables. Datos: volumen procesado y principales decisiones de limpieza. Una página adicional entrena el LightGBM en vivo, en CPU, en unos 80 segundos, y verifica que reproduce el AUC de la corrida oficial.

20. **Documentación técnica** con la descripción de cada algoritmo, las garantías contra fuga de información y el glosario.

21. **Código C de la alerta a bordo** con su prueba de paridad.

Tabla 11. Glosario.

Término	Significado
DPF	Filtro de partículas diésel. Retiene el hollín y se limpia quemándolo.
Regeneración	Combustión del hollín acumulado. Necesita temperatura sostenida, es decir, trayectos suficientemente largos.
AUC	Probabilidad de que el modelo asigne más riesgo a un caso positivo que a uno negativo. 0,5 es azar y 1 es perfecto.
AP	Precisión promedio. Resume precisión y detección cuando los positivos son pocos.
Fuera de fold	Predicción hecha por un modelo que no vio ese vehículo en el entrenamiento.
Holdout	Vehículos reservados solo para reportar resultados.
Episodio de falsa alarma	Alerta en un vehículo sano sin otra alerta en los 30 días previos.
SHAP	Contribución de cada variable a una predicción individual.

• **Seguridad y Privacidad**

La solución se diseñó para no agregar superficie de ataque al vehículo. Trabaja con datos que Ford ya recolecta, no escribe sobre ningún sistema de control del motor y sus salidas son informativas: una recomendación o un aviso. Un error o una manipulación del modelo puede generar una alerta de más o de menos, pero no puede actuar sobre el vehículo.

Se revisaron las normas aplicables a una solución de este tipo:

22. **UNECE R155 e ISO/SAE 21434.** El reglamento R155, obligatorio para homologar vehículos en la Unión Europea y otros mercados desde 2024, exige un sistema de gestión de ciberseguridad durante todo el ciclo de vida. La norma ISO/SAE 21434 define cómo hacerlo, incluido el análisis de amenazas y evaluación de riesgos o TARA. La tabla siguiente es un TARA simplificado de la solución.

23. **UNECE R156 e ISO 24089.** Regulan las actualizaciones de software, incluidas las remotas. La versión a bordo y sus reentrenos deben distribuirse por el canal de actualización firmado de Ford.

24. **ISO/IEC 27001.** Sistema de gestión de seguridad de la información para la parte en la nube: control de acceso, cifrado y registro de auditoría.

25. **Ley 25.326 de Protección de Datos Personales de Argentina** y, según el mercado,

normas equivalentes como el GDPR europeo o la LGPD de Brasil. Los hábitos de manejo de un vehículo identificable son datos personales: requieren finalidad declarada, minimización y consentimiento.

Tabla 12. Análisis de amenazas y riesgos simplificado según ISO/SAE 21434.

Activo y amenaza	Impacto	Mitigación	Riesgo residual
Telemetría en la nube: filtración	Exposición de hábitos del cliente	Identificador seudonimizado, cifrado en tránsito y en reposo, acceso por roles, retención limitada. El modelo no usa GPS.	Bajo
Datos de entrada: manipulación o envenenamiento	Alertas de más o de menos	Validación de rangos físicos en la ingesta, monitoreo de deriva, reentrenamiento con aprobación y comparación contra el modelo vigente antes de publicar.	Bajo
Canal de notificación: suplantación	Phishing al cliente usando alertas falsas	Avisos solo por la app oficial y el concesionario, sin enlaces de pago ni pedido de datos.	Bajo
Modelo a bordo: alteración	Pérdida de la alerta temprana	Actualización firmada según R156, arranque seguro del módulo. El modelo solo informa y no actúa sobre el motor.	Muy bajo
Código a bordo: explotación de memoria	Ejecución de código no autorizado	C99 sin memoria dinámica ni recursión, estado de tamaño fijo, tiempo de ejecución acotado.	Muy bajo
Disponibilidad de datos: corte de una señal	Riesgo mal estimado	Reconstrucción desde señales redundantes, como se hizo con las regeneraciones, y alertas de calidad de datos.	Bajo
Recomendaciones: inferencia de rutinas	Revelar horarios del conductor	Visibles solo para el titular, calculadas con 12 semanas, sin ubicación y sin compartir con terceros.	Bajo

Durante el desarrollo, el dataset confidencial se procesó solo en equipos locales, sin subirlo a servicios externos ni al repositorio, y el archivo con las tablas del modelo entrenado tampoco se versiona.

● Factibilidad Económica

La solución se apoya en infraestructura que Ford ya tiene: la telemetría llega hoy a la nube y la red de concesionarios y la app son los canales de contacto. Lo nuevo es software, construido íntegramente con herramientas de código abierto sin costo de licencia: Python, DuckDB, LightGBM, PyTorch, scikit-survival, SHAP y Streamlit.

Tabla 13. Costos de implementación y mantenimiento. Valores estimados, a validar con Ford.

Concepto	Estimación	Comentario
Licencias de software	USD 0	Todo el stack es de código abierto.
Cómputo en la nube	USD 3.500 a 5.000 por año	Una máquina de 8 núcleos y 32 GB cuesta entre USD 0,31 y 0,40 por hora en AWS, Azure o Google Cloud, más almacenamiento. Alcanza para puntuar la flota cada día y reentrenar cada mes.
Integración inicial	4 a 6 meses de un equipo de 2 o 3 personas	Conexión con la ingesta de telemetría, la app y el sistema de concesionarios. Costo interno a valorizar por Ford.
Hardware a bordo	USD 0	Se instala por actualización remota en módulos existentes: 290 bytes de estado y unos 17 KB de tablas.
Mantenimiento	Parcial de 1 persona	Reentrenamiento mensual automatizado, monitoreo de deriva y de calidad de datos, ajuste del volumen de alertas a la capacidad de los concesionarios.

Para el beneficio se usó el modelo económico del dashboard, con supuestos editables: una flota de 50.000 vehículos diésel, 0,05 eventos por vehículo y año, USD 1.800 de costo correctivo por evento entre garantía, reparación y traslado, USD 3 por cada notificación al cliente, USD 200 por acción preventiva y un 60 % de eventos evitados cuando la alerta llega a tiempo. Las tasas de detección y de falsas alarmas son las medidas.

Los costos se contrastaron con precios de referencia. Para una Ford Ranger, limpiar el filtro cuesta unos USD 400 a 650 y reemplazarlo por uno original USD 2.400 a 3.300, así que USD 1.800 es un promedio entre ambos casos. La acción preventiva equivale a una regeneración forzada en el concesionario, de costo similar a un service básico, y una llamada de seguimiento cuesta entre USD 1 y 3. La tasa de eventos y la fracción evitada no tienen una fuente pública: son supuestos a confirmar con Ford.

Tabla 14. Modelo económico con las tasas medidas en el holdout.

Resultado anual	ECU actual	Powertrain Health Copilot
Eventos anticipados	1.384	2.188
Eventos evitados	830	1.313
Notificaciones enviadas	31.400	32.510
Ahorro neto estimado	USD 1.123.658	USD 1.827.471
Ahorro incremental del sistema		USD 703.813




Figura 10. Sensibilidad del ahorro neto anual a la fracción de eventos evitados, para 50.000 vehículos.

Con las tasas más conservadoras de la validación temporal para vehículos nuevos, 64 % de detección contra 53 % de la ECU y con menos falsas alarmas, el ahorro incremental es de USD 277.175 por año. El rango razonable queda entonces entre USD 0,3 y 0,7 millones por año cada 50.000 vehículos, frente a un costo de operación de unos USD 5.000 anuales más la integración inicial. El caso se sostiene mientras un evento cueste más de unos USD 340; si la mayoría se resolviera con una limpieza, el ahorro directo sería bajo. Además, según la cobertura de garantía, parte de ese ahorro es del cliente y no de Ford.

Hay beneficios que el modelo no cuantifica: menos vehículos detenidos y menos traslados en grúa, mejor percepción de calidad, turnos de taller planificados con anticipación y un canal de contacto con el cliente basado en un consejo útil. El supuesto más incierto es la fracción de eventos evitados, que depende de que el conductor siga la recomendación; por eso el primer paso de Trabajo Futuro es medirla.

● Valor Diferencial e Innovación

La solución combina en un mismo sistema cosas que habitualmente se resuelven por separado:

26. **De reactivo a predictivo, con una comparación justa.** El sistema no se compara contra el azar sino contra la advertencia actual de la ECU, a igual tasa de falsas alarmas. Así el valor agregado es directo: 32 puntos más de eventos detectados.
27. **De predictivo a prescriptivo.** No solo dice que hay riesgo: indica el cambio de hábito más fácil que lo reduce y en qué momento de la semana del conductor hacerlo. La recomendación sale de un modelo con restricciones físicas que garantizan que un mejor hábito nunca aumente el riesgo, y la definición de trayecto apto se midió en los datos.
28. **Tres niveles de despliegue desde el mismo conocimiento.** Ranking de flota en la nube para la red de concesionarios, recomendación en la app para el conductor y alerta a bordo en C que funciona sin conectividad.
29. **Robustez ante datos imperfectos.** Cuando la señal de regeneraciones se cortó para toda la flota, se reconstruyó desde otra señal y se validó contra la original. Una solución en producción va a enfrentar cortes así.
30. **Alerta con volumen controlado.** El umbral relativo a la flota fija cuántas alertas salen por día, lo que permite dimensionar la atención de los concesionarios y evita saturarlos si la flota entera cambia.
31. **Rigor y transparencia.** Test automático contra fuga de información, control del sesgo de cohorte, validación temporal, intervalos de confianza por vehículo y reporte explícito de los resultados que no mejoraron.

Tabla 15. Situación actual frente a la solución propuesta.

	Hoy	Con Powertrain Health Copilot
Momento del aviso	Cuando el filtro ya está sobre el límite	Meses antes, cuando el patrón empieza a cambiar
Eventos anticipados	55 %	88 % con las mismas falsas alarmas
Qué hace el cliente	Ir al taller	Un cambio de hábito concreto; taller solo si no alcanza
Explicación	Un mensaje de estado	Qué hábitos pesan en el riesgo de su vehículo
Planificación del concesionario	Demanda imprevista	Ranking diario y volumen de alertas acordado

● Trabajo Futuro

El camino a producción está planteado en fases que reducen el riesgo en cada paso:

Tabla 16. Hoja de ruta de implementación.

Fase	Duración	Qué se hace	Criterio para avanzar
1. Modo sombra	3 meses	El sistema corre sobre la flota real sin notificar. Se comparan sus alertas con los eventos que ocurren.	Detección y falsas alarmas prospectivas al menos iguales a las de la ECU
2. Piloto con intervención	6 meses	Grupo que recibe recomendaciones y grupo de control asignados al azar.	Reducción medida de eventos en el grupo intervenido
3. Despliegue en la nube	Continuo	Reentrenamiento mensual automático, monitoreo de deriva y volumen de alertas acordado con los concesionarios.	AUC y detección estables mes a mes
4. Alerta a bordo	Según ciclo de ECU	Integración en el módulo telemático por actualización remota, validación en banco y en vehículo.	Paridad y consumo de recursos verificados en el hardware

Las mejoras con mayor retorno ya están medidas. La principal es **sumar vehículos con evento**, ya que cada duplicación agrega unos 0,03 de AUC. También ayudaría contar con la fecha de inicio de los síntomas en lugar de la fecha de identificación en el taller, restablecer el envío de la bandera de regeneraciones y sumar las señales del anexo que no vinieron en el dataset, como el porcentaje de carga del DPF y la presión de neumáticos. Del lado del modelo, con datos de producción conviene reevaluar el peso de la red neuronal en el ensamble y retomar su pre-entrenamiento con toda la flota sin etiquetar. Quedan además dos líneas opcionales: entrenamiento que ignore explícitamente el país y la cohorte, y un modelo jerárquico que lea los viajes individuales.

Replicabilidad. El método no depende del DPF en particular. Sirve para cualquier degradación que dependa del uso y deje rastro en la telemetría, como la recirculación de gases EGR, el catalizador, la batería con uso de viajes cortos o el aceite. Para aplicarlo a otro mercado o a otro modelo alcanza con las mismas tablas de viajes y eventos. El umbral relativo se adapta solo al tamaño y al riesgo de cada flota, el código corre en CPU con recursos configurables y todo el pipeline se reproduce con un comando por etapa.

● Conclusiones

Powertrain Health Copilot convierte la telemetría que Ford ya recibe en un sistema que anticipa la saturación del filtro de partículas, explica por qué ocurre y le dice al conductor qué hacer para evitarla.

- 32. **Detecta el 88 % de los eventos antes de que ocurran**, contra el 55 % de la advertencia actual, con la misma tasa de falsas alarmas y una anticipación mediana de 125 días o unos 4.350 km.
- 33. **Es explicable y accionable**: cada alerta llega con los hábitos que la causan y con una recomendación medida en los datos, como sumar un trayecto de 20 minutos que completa la limpieza en el 93 % de los casos.
- 34. **Es viable y barato**: usa datos existentes, herramientas de código abierto, corre en CPU y tiene una versión a bordo de 290 bytes por vehículo. El ahorro estimado va de USD 0,3 a 0,7 millones por año cada 50.000 vehículos.
- 35. **Está evaluado con honestidad**: hacia el futuro la ventaja se mantiene pero es menor, y se identificó cómo cerrarla con reentrenamiento mensual y más vehículos con evento.

Próximos pasos concretos

1. Correr el sistema en modo sombra durante tres meses sobre la flota real.
2. Lanzar un piloto aleatorizado para medir cuántos eventos evitan las recomendaciones.
3. Desplegar en la nube con reentrenamiento mensual y el volumen de alertas acordado con los concesionarios.
4. Integrar la alerta a bordo mediante actualización remota.